

KYM Kamera Görüntüsü Kullanarak Kızılötesi Kameralarda Düzensizlik Giderme

Bahri ABACI


Danışman: Doç. Dr. Seniha Esen YÜKSEL ERDEM

Amaç


- Tipik bir kamera iki boyutlu bir algılayıcı dizisi ile lensten geçen ışımayı algılamaktadır
- Bu dizideki algılayıcı farklılıkları, lens bozulmaları, kameranın iç ısı ve malzeme toleransları nedeniyle her algılayıcının tepkisi farklıdır
- Bu tepki farkı homojen bir yüzeye bakıldığında Sabit Örüntü Gürültüsü olarak bilinen bir gürültü çeşidi olarak görüntüye yansımaktadır
- Bu tez kapsamında kızılötesi kameralarda sık karşılaşılan bu fenomenin düzeltilmesine yönelik bir çalışma yapılacaktır
- Yöntem, gürültü giderimi için KYM kamera görüntülerden sağlanan öncül bilgiyi de kullanacaktır

Kızılötesi Kamera

- Kızılötesi kameralar, nesnelerin yaydığı veya yansıttığı kızılötesi ışığı algılayan cihazlardır.
- Bu kameralar, nesnelerin yüzey sıcaklıklarını tespit etmek ve görüntülemek için kullanılır.
- Gece görüş sistemleri, termal görüntüleme, güvenlik sistemleri ve tıbbi görüntüleme gibi birçok alanda yaygın olarak kullanılır.




Kızılötesi Nedir?



- Kızılötesi ışık, elektromanyetik spektrumun görünür ışık ve mikrodalga arasında yer alan bir bölgesidir.
- Bu bölge, yaklaşık 0.75 mikrometreden (μm) 1000 mikrometre (1 mm) kadar uzanan dalga boylarını kapsar.
- Görünür ışığın ötesinde yer aldığı için insan gözü tarafından doğrudan algılanamaz.

Kızılötesi Işıma

- **Kara Cisim Işıması** maddenin sıcaklığına bağlı yaydığı elektromanyetik ışımadır
- Planck Yasası mutlak sıcaklığı (T) bilinen bir kara cismin yapacağı ışıma şiddetini modeller.




Kızılötesi Kamera Çalışma Prensibi

- Cisim tarafından yapılan ışımanın tüm dalga boylarında integrali alınırsa, cismin yaydığı ışıma şiddeti bulunur

$$M(T) = \int_0^{\infty} B(\lambda, T) d\lambda = \sigma T^4 \quad [\text{W} \cdot \text{m}^{-2}]$$


- Kamera tarafından görülen ışıma miktarı ise; pikselin açısı (α), lens çapı (d) ve odak uzaklığı (f) ile ilintilidir



$$I(x, y, T) = M(T) \cdot \Omega = M(T) \left(\frac{\pi}{4} \right) \left(\frac{d}{f} \right)^2 \cos^4 \alpha$$

Düzensizlik Problemi

- Teorik ışıma $I(x, y, T)$; detektör kaynaklı hatalar nedeniyle farklı ölçülmektedir
- Bu hata üretim toleransı, malzeme farklılıkları, çalışma sıcaklıkları vb. nedenlerle oluşan Sabit Örüntü Gürültüsünü (FPN) oluşturur
- Bu gürültü görüntü kalitesinin düşmesine ve hatalı tespitlere neden olur



Termal Kamerada Düzensizlik Problemi


- Kızılötesi bantta yayılan enerji çok daha düşük olduğundan, algılayıcı farkları daha görünür olmaktadır
- KYM bantlarında enerji ve içerik kontrastı yüksek olduğundan bu hata daha az görülmektedir
- Kızılötesi sensörler düşük sıcaklıkları da algılayan birimler olduklarından kameranın iç ısısından da etkilenmektedir
- KYM kameralar perde ile tamamen kara ortam oluşturabilirken, termal kameralarda kara ortam oluşturmak daha zordur

Önerilen Yöntem

- KYM kamera görüntüsünü kullanarak termal kamera görüntüsünde düzensizlik gideren bir yöntem önerilmektedir.
- Referans sıcaklık düzlemine veya çok uzun süreli gözlemlere ihtiyaç duymayan bir çözüm önerilmektedir.
- Çoğu sistemde kızılötesi kamera ve KYM kamera birlikte kullanıldığından, yöntem ek bir maliyet veya zorluk getirmemektedir.




Önerilen Yöntem-1



- N tane görüntü $\mathbf{T}_n, \mathbf{I}_n$ toplanır.
- KYM ve kızılötesi görüntülerden $\mathbf{P}_n = f(\mathbf{I}_n, \mathbf{T}_n)$ kızılötesi verisi tahminlenir
- $\mathbf{P}_n, \mathbf{T}_n$ birlikte kullanılarak FPN kestirilir

Önerilen Yöntem-2



- N tane görüntü $\mathbf{T}_n, \mathbf{I}_n$ toplanır.
- $\mathbf{z}_n = E(\mathbf{T}_n)$ ve $\mathbf{c}_n = H(\mathbf{I}_n)$ kodlanmış ve saklı vektörler hesaplanır
- $D(\mathbf{z}_n, \mathbf{c}_n)$ birlikte kullanılarak FPN kestirilir

KYM Kamera Görüntüsü Kullanarak Kızılötesi Kameralarda Düzensizlik Giderme 1. Dönem Çalışmaları


İçerik

- KYM-Kızılötesi Dönüşüm Yöntemleri
 - Üretici Çekişmeli Ağlar
 - Yayılım Modelleri
 - Kullanılan Metrikler
- Literatür İncelemesi
- KYM-Kızılötesi Dönüşüm Çalışmalarım
- Çalışma Planı

GAN: Üretici Çekişmeli Ağlar (Goodfellow vd., 2014)


- GAN yapay zeka alanında kullanılan üretici türünde bir derin öğrenme modelidir
- Üretici ve Ayırt Edici olmak üzere iki derin öğrenme ağının birlikte çalıştığı bir yapıdır
- Üretici (G) rastgele bir girdiden gerçek görüntülere benzer bir çıktı üretmeye çalışırken;
- Ayırt Edici (D) gerçek veriler ile üretici ağın çıktısını ayırt etmeyi öğrenmektedir
- İki ağın çekişmeli öğrenmesi ile üretici gerçek görüntülere daha benzer olmayı öğrenirken, ayırt edici daha seçici olmayı öğrenir
- Görüntü ve ses üretimi, oyun tasarımı, sanat ve daha pek çok alanda kullanılmaktadır.

Üretici Ağ Yapısı



- z rastgele bir gürültü vektörü olmak üzere $x_f = G(z)$ çıktısını üretir
- Ayırt Edici hatasından geri yayılım yoluyla eğitilir
- $L_G = \min_G E_{z \sim p_z(z)} [-\log(D(G(z)))]$

Ayırt Edici Ağ Yapısı



- $x_r \sim p(x)$ gerçek imgesi ile x_f sahte görüntüyü ayırt etmeye çalışır
- Hata bu ağın çıkışından ölçülür
- $L_D = \max_D E_{x_r \sim p_{data}(x)} [\log D(x_r)] + E_{z \sim p_z(z)} [\log(1 - D(x_f))]$


cGAN: Koşullandırılmış Üretici Çekişmeli Ağ (Mirza vd., 2014)

- GAN modeline herhangi bir koşulun verilmesine olanak sağlayan bir modeldir
- Koşullandırma, modelin belirli özelliklere veya veri sınıflarına uygun veri üretmesini mümkün kılmaktadır.
- Bu koşula hem Üretici, hem Ayırt Edici ağın erişimi bulunmaktadır
- Metin-Görüntü dönüşümü, görüntü düzenleme ve sahne yaratma gibi alanlarda kullanılmaktadır

A small yellow bird with a black crown and a short black pointed beak




GAN Yapısı



- GAN yapısında çıktı kontrol edilemez, sonuçlar rastgele üretilir
- Genellikle eğitim yapılan alanda veri oluşturma için kullanılır

cGAN Yapısı




- cGAN yapısında çıktı kontrol vektörü ile kontrol edilir
- Belirli bir tarza veya konuya özelleştirilmiş veri oluşturma için kullanılır

pix2pix: Görüntü-Görüntü Dönüşüm Ağı (Isola vd., 2017)

- Pix2pix temelde cGAN yapısına dayalı bir koşullu üretici ağ yapısıdır
- GAN eğitimi sadece etiketsiz girdiler ile yapılırken, pix2pix modeli girdi-çıkı çiftlerine ihtiyaç duymaktadır
- cGAN modellerindeki c koşul vektörünü, girdi görüntüsü olarak almaktadır
- GAN kaybına ek olarak, beklenen çıktı ile Üretici ağın çıktısı arasındaki fark da kullanılmaktadır




cGAN Yapısı



- cGAN yapısında çıktı kontrol vektörü ile kontrol edilir
- Girdide yer alan z nedeniyle farklı sonuçlar üretebilir
- Belirli bir tarza veya konuya özelleştirilmiş veri oluşturma için kullanılır


pix2pix Yapısı



- Çıktı y_r girdisine bağlı oluşturulur
- y_r statik olduğundan sonuç her seferinde aynıdır
- x_r beklenen çıktı üretici ağını eğitmek için de kullanılır
- $L_G = \min_G E_{x,y} [\log(D(G(y_r), x_r))] + \|x_r - G(y_r)\|_1$

CycleGAN: Döngüsel Görüntü Dönüşüm Ağı (Zhu vd., 2017)

- İki GAN modelinin birbirlerinin çıktılarını kullanması prensibi ile çalışır
- Klasik GAN yapılarına benzer şekilde etiketli veri ihtiyacı bulunmamaktadır



Kaynak: referans makale


CycleGAN: Döngüsel Görüntü Dönüşüm Ağı (Zhu vd., 2017)

- CycleGAN yapıları iki üretici G_X, G_Y ve iki ayırt edici D_X, D_Y ağıın birlikte çalışması ile oluşturulmuştur
- Bu ağlarda $G_X: X \rightarrow Y, G_Y: Y \rightarrow X$ bölgeleri arasında geçiş yapmaktadır
- D_X, D_Y ise sırasıyla $\{x, G_Y(y)\}$ ve $\{y, G_X(x)\}$ çiftlerini ayırt etmeyi amaçlamaktadır
- Bu iki üretici ağ Tutarlılık Kaybı denilen bir kayıp fonksiyonu ile birbirine bağlanmıştır

$$L_{cyc}(G_X, G_Y) = E_{x \sim p_{data}(x)} [\|G_Y(G_X(x)) - x\|_1] + E_{y \sim p_{data}(y)} [\|G_X(G_Y(y)) - y\|_1]$$


- Tutarlılık kaybı $x \rightarrow Y \rightarrow x$ ve $y \rightarrow X \rightarrow y$ dönüşümlerinden sonra girdi ile çıktının benzer olmasını zorlamaktadır

pix2pix Yapısı



- Çıktı y_r girdisine bağlı oluşturulur
- x_r hem üretici hem ayırt edici de kullanılır
- x_r, y_r görüntü çiftleri gerekir
- Üretici x_r, y_r arası hatadan eğitilir

cycleGAN Yapısı



- Çıktı y_r girdisine bağlı oluşturulur
- x_r sadece ayırt edici de kullanılır
- x_r, y_r eşlenik olması gerekmez
- Üretici döngüsel tutarlılık kaybı ile eğitilir


$$L_{cons} = E_{y \sim p_{data}(y)} \left[\|G_X(G_Y(y)) - y\|_1 \right]$$

Yayılım Modelleri (Ho vd., 2020; Rombach vd., 2022)


- Yayılım modelleri, yeni nesil bir veri üretme yöntemi olarak ortaya çıkmıştır
- Bu modeller iki adımlı bir süreç ile eğitilir;
 - Veriye adım adım gürültü ekleyen **İleri Yayılım**,
 - Adım adım gürültü kaldıran **Geri Yayılım**
- GAN yapılarından farklı olarak bu yapılarda eğitilen tek bir derin öğrenme ağı bulunur
- GAN yapıları saklı uzaydaki gürültüden çıktıyı oluştururken, bu yapılarda çıktı girdi gürültüsünün iteratif kaldırılması ile elde edilir

DDPM: Gürültü Kaldırıcı Olasılıksal Yayılım Modelleri (Ho vd., 2020)


- u-Net mimarisine dayalı gürültü giderme ağını iteratif olarak kullanan bir yayılım modelidir



DDPM: Gürültü Kaldırıcı Olasılıksal Yayılım Modelleri (Ho vd., 2020)




- İleri yayılım adımında $x_t = \sqrt{1 - \beta_t}x_{t-1} + \sqrt{\beta_t}\epsilon$, $\epsilon \sim \mathcal{N}(0, I)$ ile gürültülü imgeler elde edilir
- Geri yayılım adımında $x_{t-1} = G(x_t, t)$ doğrudan görüntü tahmin edilmek yerine $\epsilon = x_t - x_{t-1} = \epsilon_\theta(x_t, t)$ gürültü tahmin edilir
- Öğrenme işlemi $\mathcal{L}(\theta) = E_{t, x_0, \epsilon}[|\epsilon - \epsilon_\theta(x_t, t)|^2]$ kaybının optimize edilmesi ile yapılır
- Ağın hangi iterasyon adımında olduğunu gösteren t , pozisyonel kodlama ile ağa beslenir
- Bu işlemler $t: T \rightarrow 0$ için tekrarlandığında gürültüsüz bir imge elde edilir



LDM: Saklı Yayılım Modelleri (Rombach vd., 2022)

- DDPM ağının yüksek çözünürlükteki yavaşlık sorununu çözmek için önerilmiştir
- Doğrudan verinin ileri-geri yayılımı yerine, saklı uzayda yayılım yaparak çalışmaktadır



Üretici Ağlar için Başarı Ölçüm Metrikleri

- Üretici ağların çoğunda çıktı, hedef dağılımdan rastgele üretilen bir örnektir
- Çıktı için bir referans bulunmadığından metrikler de buna uygun olmalıdır
- Üretici ağ başarısı iki başlık altında toplanabilir

Benzerlik

üretilen sonuçların hedef veri kümesi ile olan görsel ve algısal benzerliği



Kaynak: DA-GAN: Instance-level Image Translation by Deep Attention Generative Adversarial Networks, 2018

Çeşitlilik

üretilen sonuçların birbirinden ne kadar farklı olduğu



Kaynak: Diverse Image Generation via Self-Conditioned GANs, 2020

Üretici Ağlar için Başarı Ölçüm Metrikleri: ISC

- Inception Score (ISC): Salimans vd., 2016 tarafından üretici ağların eğitilmesini iyileştirmek amacıyla önerilmiştir
- Bu skor önceden eğitilmiş Inceptionv3 ağının çıktıları kullanılarak hesaplanır
- Bir $x = G(z)$ çıktısı ağa verilerek $p(y|x)$ koşullu olasılık dağılımı elde edilir
 - Üretilen çıktı gerçeğe yakınsa y vektörünün entropisi düşük olacaktır
 - Diğer yandan ağın çeşitliliği için de $p(y) = \int p(y|x)p_G(x) dx$ dağılımının yüksek entropiye sahip (tüm sınıflar eşit) olması beklenmektedir
- Bu iki bilgi kullanılarak IS aşağıdaki şekilde tanımlanır

$$D_{IS} = \exp\{E_x[\text{KL}(p(y|x) \parallel p(y))]\}$$

Üretici Ağlar için Başarı Ölçüm Metrikleri: FID

- FID (Fréchet Inception Distance): Heusel vd., 2017 tarafından önerilen yöntem GAN çıktılarının gerçek imgelere olan benzerliğini ölçmek için geliştirilmiştir
- Inceptionv3 modelinin 2048 uzunluklu son katmanı öznitelik vektörü olarak kullanılmaktadır
- Yöntem ağın çıktılarının ve gerçek imgelerin bir Gaussian dağılım ile ifade edilebileceği fikrine dayanır
- μ_r, Σ_r gerçek imgelere, μ_g, Σ_g üretilen imgelere ait ortalama ve kovaryans olmak üzere

$$D_{FID} = \|\mu_r - \mu_g\|^2 + \text{Tr} \left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2} \right)$$

Üretici Ağlar için Başarı Ölçüm Metrikleri: KID

- KID (Kernel Inception Distance): Binkowski vd., 2021 tarafından önerilen yöntem GAN çıktılarının gerçek imgelere olan benzerliğini ölçmek için geliştirilmiştir
- Inceptionv3 modelinin 2048 uzunluklu son katmanı öznitelik vektörü olarak kullanılmaktadır
- Gerçek ve üretilen hedef kümelerindeki tüm vektörlerin çapraz hesaplaması ile bulunur
- $K(x, y)$ bir çekirdek fonksiyonu olmak üzere KID aşağıdaki şekilde hesaplanır

$$D_{KID} = E_x[K(x, x')] + E_y[K(y, y')] - 2E_{x,y}[K(x, y)]$$

Üretici Ağlar için Başarı Ölçüm Metrikleri: LPIPS

- LPIPS (Learned Image Patch Similarity): Zhang vd., 2018 tarafından önerilen yöntem iki imgenin algısal benzerliğini ölçmek için kullanılmaktadır
- VGG16, AlexNET veya SqueezeNet gibi modellerin son katmanı öznitelik vektörü olarak kullanılmaktadır
- Hesaplama doğrudan x , y öznitelik vektörlerinin Öklid uzaklığı ile bulunmaktadır

$$D_{LPIPS} = E_{x,y}[(x - y)^2]$$

- Üretici ağlarda çıktı bilinemediğinden, ağın rastgele çıktıları arasındaki ortalama LPIPS ölçümü raporlanır
- Bu değer ağın ne kadar çeşitli sonuçlar ürettiğini göstermektedir

Üretici Ağlar için Başarı Ölçüm Metrikleri


Metrik	Inception Score (IS)	Fréchet Inception Distance (FID)	Kernel Inception Distance (KID)	Learned Image Patch Similarity (LPIPS)
Öznitelik	Inception Sınıflandırma Skorları	Inception Öznitelikleri	Inception Öznitelikleri	VGG Öznitelikleri
Uzaklık Fonksiyonu	KL İraksaması	Gaussian Uzaklık Fonksiyonu	Çekirdek Uzaklık Fonksiyonu	Öklid Uzaklığı
Ana Odak	Çeşitlilik ve Kalite Ölçümü	Gerçek İmgeler ile Benzerlik	Gerçek İmgeler ile Benzerlik	Çeşitlilik veya Referans ile Benzerlik
Kısıtlar	Gerçekçi olmayan imgelerde hatalı sonuçlar üretebilmektedir.	Kovaryans hesabı nedeniyle yoğun işlem içerir	Çekirdek fonksiyonu özniteliklere uygun seçilmelidir	Üretilen imgelerin kalitesi hakkında bir fikir vermez

KYM Görüntüden Kızılötesi Görüntü Kestirimi

- ThermalNet: A Deep Convolutional Network For Synthetic Thermal Image Generation (2017)
- ThermalGAN: Multimodal Color-to-Thermal Image Translation for Person Re-Identification in Multispectral Dataset (2018)
- Synthetic Data Generation for End-to-End Thermal Infrared Tracking (2018)
- Generating Infrared Image From Visible Image Using Generative Adversarial Networks (2019)
- Sparse GANs for Thermal Infrared Image Generation From Optical Image (2020)
- Thermal Image Processing via Physics-Inspired Deep Networks (2021)
- InfraGan: A GAN Architecture To Transfer Visible Images To Infrared Domain (2022)
- MWIRGAN: Unsupervised Visible-to-MWIR Image Translation with Generative Adversarial Network(2023)
- Visible to Infrared Image Translation Based on an Improved CGAN (2023)
- Visible to Thermal Image Translation for Improving Visual Task in Low Light Conditions(2023)
- T2V-DDPM: Thermal to Visible Face Translation using Denoising Diffusion Probabilistic Models(2023)


ThermalGAN: Multimodal Color-to-Thermal Image Translation for Person Re-Identification in Multispectral Dataset (Kniaz vd., 2018)

- RGB kişi görüntülerinin, kızılötesi kümesinde teşhis edilmesini sağlayan bir yöntemdir
- A RGB, B termal görüntü ve $\hat{B}_i$ termal kestirim olmak üzere akışı şekildeki gibidir




ThermalGAN: Multimodal Color-to-Thermal Image Translation for Person Re-Identification in Multispectral Dataset (Kniaz vd., 2018)

- $\hat{B}_i = G(T_i, A)$ sıcaklık kontrol vektörüne bağlı thermalGAN ağının çıktısı aşağıdaki ağ yapısı ile oluşturulmuştur
- İki kademeli tasarımda ilk aşamada $\hat{S}$ bölütleme çıktısı, ikinci kademede $\hat{R}$ lokal sıcaklık farkları kestirilmiştir



ThermalGAN: Multimodal Color-to-Thermal Image Translation for Person Re-Identification in Multispectral Dataset (Kniaz vd., 2018)


- Yöntem ThermalWorld VOC veri seti üzerinde eğitilmiş, ThermalWorld ReID veriseti üzerinde test edilmiştir



- Eğitimler 1080 Ti GPU üzerinde yaklaşık 6 gün sürmüştür
- Başarı anket ve LPIPS uzaklık metriği ile ölçülmüştür
- Yöntem $L_d = 0.167$ skoru ile, cVAE-GAN (0.153) ve pix2pix(0.131) yöntemlerinden daha çeşitli görüntüler üretmiştir


Synthetic Data Generation for End-to-End Thermal Infrared Tracking (Zhang vd., 2018)

- Tipik bir takip algoritması korelasyon filtresini derin öğrenme ağından elde edilen özniteliklerden öğrenmektedir
- Çok fazla veri gerektiğinden yöntemler termal kameralarda geliştirilmeye açıktır
- Çalışmada RGB takip veri setlerinin, termal takip algoritmaları geliştirmek amacıyla kullanılabilmesine yönelik bir yöntem önerilmektedir




Synthetic Data Generation for End-to-End Thermal Infrared Tracking (Zhang vd., 2018)

- Önerilen yöntem pix2pix ve cycleGAN gibi modelleri bu alanda kullanmıştır
- Çalışmada eğitim için KAIST, CVC-14, LITIV2012 gibi veri setlerinden alınan toplam 87bin imgelik bir küme kullanılmıştır
- Dönüşüm başarısı KAIST veri setinde Öklid uzaklığı ile ölçülmüştür
- Pix2Pix ortalama 35.3, CycleGAN ortalama 69.5 gri seviye hatalı sonuç üretmiştir



MWIRGAN: Unsupervised Visible-to-MWIR Image Translation with Generative Adversarial Network (Uddin vd., 2023)

- Çalışmada RGB görüntülerin MWIR dalga boyu karşılıklarının elde edilmesi için cycleGAN tabanlı bir yöntem önerilmiştir
- Yöntem iki üretici ve iki ayırt edici ağıdan oluşmaktadır
- Yöntem eşlenmiş RGB ve kızılötesi görüntü çiftlerine ihtiyaç duymadığından, eğitimcisz öğrenme olarak sınıflandırılmıştır



MWIRGAN: Unsupervised Visible-to-MWIR Image Translation with Generative Adversarial Network (Uddin vd., 2023)

- Klasik cycleGAN yapısında bulunan GAN ve döngü tutarlılık kayıplarının yeterli olmadığı vurgulanmıştır

$$L_{GAN} = L_{GAN}(G_Y, D_Y, X, Y), L_{GAN}(G_X, D_X, Y, X)$$

$$L_{CYC} = \|G_Y(G_X(X)) - X\|_1 + \|G_X(G_Y(Y)) - Y\|_1$$


- Bu nedenle çalışmada ek olarak Algısal Kayıp fonksiyonu da kullanılmıştır

$$L_{PER} = \text{LPIPS}(G_Y(G_X(X)), X) + \text{LPIPS}(G_X(G_Y(Y)), Y)$$

- Yöntem Amerikan ordusu tarafından toplanan ve algoritma geliştirme çalışmaları için paylaşılan ATR veri seti üzerinde test edilmiştir
- FID skoruna göre yöntem 1.72 başarı ile CycleGAN (3.28)'in önüne geçmiştir

IR-GAN: Visible-to-Infrared Image Translation Based on an Improved CGAN (Ma vd., 2023)

- Çalışmada RGB görüntülerin NIR dalga boyu karşılıklarının elde edilmesi için cGAN tabanlı bir yöntem önerilmiştir
- Önerilen yöntem u-Net blokları yerine u-ConvNeXt blokları ile yukarı örnekleme adımını iyileştirmektedir
- Ayırt Edici ağda görüntüyü farklı boyutlarda ele alan bir ağ yapısı kullanılmıştır



IR-GAN: Visible-to-Infrared Image Translation Based on an Improved CGAN (Ma vd., 2023)


- Yöntemin önemli bir katkısı da detayları korumak için kenar bilgisini de kayıp fonksiyonuna eklemesidir

$$L_G = \arg \min_G \max_D L_{cGAN}(G_Y, D_X, X, Y) + \lambda \|G_Y(Y) - X\|_1 + \varphi L_{sobel}(G_Y(Y), X)$$

- Kenar kaybının katsayısı φ , eğitim seti üzerinde yapılan testler ile bulunmuştur
- Yöntem VEDAI ve IVFG veri kümeleri üzerinde eğitilmiş ve test edilmiştir
- Karşılaştırmada RMSE, PSNR ve SSIM gibi yöntemler kullanılmıştır
- Tüm metriklerde Pix2Pix ve ThermalGAN yöntemlerine kıyasla daha yüksek başarı raporlanmıştır


T2V-DDPM: Thermal to Visible Face Translation using Denoising Diffusion Probabilistic Models (Nair vd., 2023)

- GAN yapısından farklı, DDPM tabanlı görüntü dönüşümü yapan bir yöntemdir
- Termal kamera görüntülerinden RGB kamera görüntüsü kestirimi yapmak üzere geliştirilmiştir
- Yöntem $\mathbf{x}_T$ gürültüsünden, $\mathbf{x}_0$ imgesine giderken her adımda termal kamera görüntüsünü koşul olarak kullanmaktadır



T2V-DDPM: Thermal to Visible Face Translation using Denoising Diffusion Probabilistic Models (Nair vd., 2023)

- Test adımını hızlandırmak için; x_T ile başlamak yerine sentetik olarak üretilen y_{50}^c görüntüsünden başlamışlardır



- Yöntem VIS-TH ve ARL-VTF veri kümeleri üzerinde eğitilmiş ve test edilmiştir



Değerlendirme: KYM Görüntüden Kızılötesi Görüntü Kestirimi

- Literatürde incelenen çalışmaların çoğu pix2pix ve cycleGAN temelli yöntemler önermektedir
- Yayılım tabanlı modellerin bu alanda kullanımı yenidir ve umut veren ilk sonuçlar mevcuttur
- Yöntemler farklı veri setlerinde farklı metriklerle test edildiklerinden henüz öne çıkan bir yöntem bulunamamaktadır
- Mevcut sonuçlar spesifik uygulamalar (takip, teşhis, vb.) için iyileştirici olsa da genel bir dönüşüm yöntemi bulunmamaktadır
- Kızılötesi alan bilgisi dönüşüm ağlarına dahil edilmemiştir

KYM-Kızılötesi Dönüşüm Çalışmalarım



cescript data_scalar option added to increase data size

e959e28 · last week

History

Name	Last commit message	Last commit date
..		
dataset	data_scalar option added to increase data size	last week
models	isTrain renamed as is_train_mode	last month
options	data_scalar option added to increase data size	last week
utility	print_current_losses method updated to print cleaner message	2 months ago
.gitignore	train and test code added for pix2pix and cycleGAN models	2 months ago
requirements.txt	train and test code added for pix2pix and cycleGAN models	2 months ago
test.py	Typo fixed in test.py	last month
train.py	isTrain renamed as is_train_mode	last month

- Çalışmaların çoğu pix2pix ve cycleGAN temelli yöntemler içerdiğinden ilk olarak bu yöntemler ile testler yapılmıştır
- Her iki yöntem, yazarlar tarafından paylaşılan gerçekleştirme kullanılarak yeniden yazılmış ve bir kod tabanı oluşturulmuştur
- Oluşturulan yazılım herhangi iki uzaydan imgeleri alarak, istenilen yöntem ile dönüşüm yapmayı öğrenebilmektedir
- Kodlamalar Python dilinde, PyTorch kütüphanesi kullanılarak yapılmıştır

KYM-Kızılötesi Dönüşüm Çalışmalarım

- CATS veri seti üzerinde oluşturulan eğitim ve test kümeleri kullanılmıştır
- Eğitim seti 136x10, test seti ise 20 imgeden oluşturulmuştur
- Veri çoğaltımı için rastgele kesme ve aynalama işlemleri yapılmıştır



KYM-Kızılötesi Dönüşüm Çalışmalarım

- İmgeler her epokta rastgele* bir noktadan 256x256 boyutlarında kesilerek ağa beslenmiştir
- Eğitimler Nvidia GTX1650Ti ve AWS-EC2 altyapısı kullanılarak yapılmıştır
- Her iki yöntem 200 epok eğitilmiştir
- Parametreler Adam yöntemi ile optimize edilmiştir
- Ağın eğitimi pix2pix için 5 saat, cycleGAN için 60 saat sürmektedir

* Eğitilen yöntemin testi sırasında doğru karşılaştırma için tüm imgeler merkezden kesilmiştir

Sonuçlar

- pix2pix yöntemi gerçek görüntülere benzer sonuçlar üretebilmektedir
- Ancak piksellerde kaymalar ve dalgalanmalar görülmektedir
- cycleGAN bütünsel olarak daha tutarlı sonuçlar üretmektedir
- Ancak cycleGAN yöntemi $x \rightarrow Y \rightarrow \hat{x}$ şeklinde çalıştığından, ara imge orijinal imge ile benzerlikler göstermektedir



Çalışma Planı

Mevcut Dönem Çalışmalarım

- Kızılötesi görüntüleme teorisi üzerine araştırmalar
- KYM görüntülerden kızılötesi görüntü üretimi için literatür takibi
- Veri kümeleri araştırma ve organize etme işlemleri
- Literatürde sık kullanılan algoritmaların gerçekleştirilmesi
- Kızılötesi gürültü giderme çalışmalarına başlanamadı

İş Paketi / AY	1-3	3-6	6-9	9-12	12-15	15-24
Literatür Takibi	X	X	X	X	X	X
Verilerin Toplanması	X	X				
RGB Verilerden Kızılötesi Verilerin Kestirimi		X	X	X		
Kızılötesi Gürültü Giderme Yöntemi Geliştirilmesi			X	X	X	
Yöntem Karşılaştırma ve Sonuçların Hazırlanması						X

Gelecek Dönem Çalışmalarım

- Sentetik FPN oluşturma
- Kızılötesi dönüşümde gürültülü imgenin öncül olarak kullanılması
- Kızılötesi gürültü kaldırma literatür takibi
- İki aşamalı gürültü kaldırma çalışmaları

İş Paketi / AY	1-3	3-6	6-9	9-12	12-15	15-24
Literatür Takibi	X	X	X	X	X	X
Verilerin Toplanması	X	X				
RGB Verilerden Kızılötesi Verilerin Kestirimi		X	X	X		
Kızılötesi Gürültü Giderme Yöntemi Geliştirilmesi			X	X	X	
Yöntem Karşılaştırma ve Sonuçların Hazırlanması						X

Teşekkürler